# Conjuntos de dados e anotação

Ivandré Paraboni
EACH - USP

# Visão geral

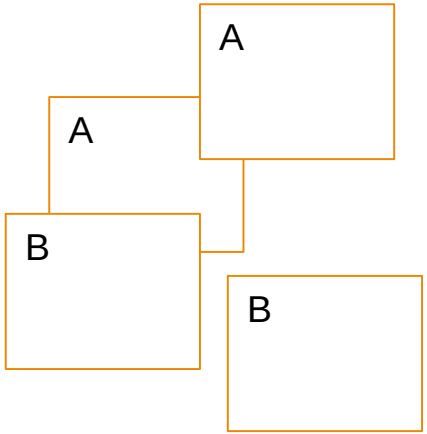
1. Coleta de dados (córpus)

2. Avaliação, métricas etc.

# Parte 1: Conjuntos de dados

# Conjuntos de dados

- Modelos de classificação de textos exigem conjunto de treinamento e teste com exemplos linguísticos **rotulados** para o problema em questão
  - Chamado de córpus
- Dois componentes:
  - Textos
  - Rótulos das classes de interesse




- Textos são fáceis de obter
- Mas e os rótulos?

# Rótulos de classes e acurácia do modelo

- Os rótulos associados aos textos são tratados pelo modelo como **verdade**
- A qualidade dos rótulos determina a qualidade do modelo
- Rótulos mal definidos, imprecisos etc. representam um limite ao que pode ser aprendido
- Conjunto de dados requer assim rótulos da mais alta qualidade possível
- Como obter rótulos?

# Córpus rotulados

- Rótulos podem ser disponibilizados naturalmente em determinados domínios
    - e.g., análise de sentimentos de opiniões sobre produtos, filmes etc. pode utilizar o número de estrelas que o avaliador atribuiu como rótulo de classe



The Witcher

★★★★☆

RESUMO DA CRÍTICA

The Witcher consegue estabelecer seus personagens e seu universo com empolgação, ainda que sua estrutura narrativa torne-se arrastada de vez em quando.

4

★★★★☆

PONTUAÇÃO

Fonte:[https://observatoriodocinema.bol.uol.com.br/](https://observatoriodocinema.bol.uol.com.br/)

# Córpus rotulados

- Rótulos podem ser disponibilizados naturalmente em determinados domínios
  - e.g., análise de sentimentos de opiniões sobre produtos, filmes etc. pode utilizar o número de estrelas que o avaliador atribuiu como rótulo de classe



The Witcher

★★★★☆

RESUMO DA CRÍTICA

texto

The Witcher consegue estabelecer seus personagens e seu universo com empolgação, ainda que sua estrutura narrativa torne-se arrastada de vez em quando.

4

classe 4 = muito bom

★★★★☆

PONTUAÇÃO

Fonte:https://observatoriodocinema.bol.uol.com.br/

# Rótulos disponibilizados pelo domínio

- Ideais sob várias perspectivas
  - representam o conhecimento real com o qual a aplicação precisa lidar
  - baixo custo de aquisição
- Mas e se os textos que eu desejo processar não são rotulados?
  - e.g., aplicação para classificar e-mails por urgência / prioridade

# Anotação de córpus

- Se não há dados naturalmente rotulados, estes terão que ser **criados**
- Tarefa árdua, de alto custo, sujeita a erros que afetam a qualidade do modelo
- Dados **não devem** ser anotados por um único indivíduo
    - e este indivíduo não deve ser o responsável pela construção do modelo
- É necessário um time de anotadores treinados na tarefa de anotação segundo um esquema de anotação pré-definido
- E depois disso é normalmente necessário medir o grau de concordância que os anotadores obtiveram entre si
    - Se concordância for baixa, anotação (ou a definição do problema) precisa ser revista

# Anotação de córpus

- Uma “ciência” dentro da área
- Grande volume de conhecimento sobre técnicas, diretrizes, esquemas de anotação, métodos de avaliação etc.
- Comunidade especializada, com eventos e veículos de publicação específicos
- Disponibilização de conjuntos de dados com diretrizes robustas pode constituir uma contribuição científica completa
    - Desde que tenha-se permissão de divulgar os dados!

# Ex.1. MTwitter

# Anotação do córpus MTwitter (Santos & Paraboni, 2018)

- Córpus de 12.8k tweets com posicionamentos (atitudes) em relação a assuntos de natureza moral (legalização de drogas, maioridade penal etc.)

- Tweets inicialmente selecionados com base em conjuntos de 7000 cada, contendo palavras-chave de interesse (e.g., “maioridade”)

- Tarefa: anotar cada tweet como sendo “favorável”, “contrário” ou “outros” em relação a cada tópico de interesse

- Anotados por um avaliador e verificados por um segundo (insuficiente?)

# Protocolo de anotação

- Diretriz: tudo que não puder ser identificado **inequivocamente** como “contra” nem como “a favor” é anotado como “outros”.
- Obviamente neste caso não existe distinção entre um tweet com posicionamento “neutro” e um sem posicionamento nenhum.

| | Twitter stances | | |
|---|---|---|---|
| Topic | for | against | other |
| Abortion | 240 | 384 | 2570 |
| Death penalty | 801 | 244 | 1518 |
| Drugs | 335 | 181 | 1482 |
| Criminal age | 243 | 240 | 1433 |
| Racial quotas | 240 | 364 | 2596 |
| Overall | 1859 | 1413 | 9599 |

# Protocolo de anotação

- Diretriz: tudo que não puder ser identificado **inequivocamente** como “contra” nem como “a favor” é anotado como “outros”.
- Obviamente neste caso não existe distinção entre um tweet com posicionamento “neutro” e um sem posicionamento nenhum.

| | Twitter stances | | |
|---|---|---|---|
| Topic | for | against | other |
| Abortion | 240 | 384 | 2570 |
| Death penalty | 801 | 244 | 1518 |
| Drugs | 335 | 181 | 1482 |
| Criminal age | 243 | 240 | 1433 |
| Racial quotas | 240 | 364 | 2596 |
| Overall | 1859 | 1413 | 9599 |

**Problemas com esta estratégia???**

# Exemplos: contra, a favor ou outros?

1. Aborto ilegal !! Que coisa mais triste

# Exemplos: contra, a favor ou outros?

1. Aborto ilegal !! Que coisa mais triste
2. Dilma pode sancionar lei que dá brecha a aborto

# Exemplos: contra, a favor ou outros?

1. Aborto ilegal !! Que coisa mais triste
2. Dilma pode sancionar lei que dá brecha a aborto
3. Abortar ou apoiar aborto é pecado de morte.

# Exemplos: contra, a favor ou outros?

1. Aborto ilegal !! Que coisa mais triste
2. Dilma pode sancionar lei que dá brecha a aborto
3. Abortar ou apoiar aborto é pecado de morte.
4. A mulher tem como se defender do estuprador, já no aborto a criança não tem como se defender.

# Exemplos: contra, a favor ou outros?

1. Aborto ilegal !! Que coisa mais triste
2. Dilma pode sancionar lei que dá brecha a aborto
3. Abortar ou apoiar aborto é pecado de morte.
4. A mulher tem como se defender do estuprador, já no aborto a criança não tem como se defender.
5. A questão é: Aborto Elétrico ou Legião?

# Exemplos: contra, a favor ou outros?

1. Aborto ilegal !! Que coisa mais triste
2. Dilma pode sancionar lei que dá brecha a aborto
3. Abortar ou apoiar aborto é pecado de morte.
4. A mulher tem como se defender do estuprador, já no aborto a criança não tem como se defender.
5. A questão é: Aborto Elétrico ou Legião?
6. Coisas que não sei lidar: homem discursando contra o aborto

# Considerações

- Custo elevado (recursos humanos + tempo)
- Pode ter subestimado os casos mais complexos
- Subjetividade é decidida por apenas dois indivíduos

# Ex.2. UstanceBR

# UstanceBR (Pereira et. al., 2026)

- Modelos supervisionados baseados em *deep learning* exigem grandes massas de dados rotulados, e com classes bem definidas

# UstanceBR (Pereira et. al., 2026)

- Modelos supervisionados baseados em *deep learning* exigem grandes massas de dados rotulados, e com classes bem definidas

- Objetivo: produzir um recurso para detecção de posicionamentos com maior número de exemplos extraídos da rede social Twitter/X.

# UstanceBR (Pereira et. al., 2026)

- Modelos supervisionados baseados em *deep learning* exigem grandes massas de dados rotulados, e com classes bem definidas

- Objetivo: produzir um recurso para detecção de posicionamentos com maior número de exemplos extraídos da rede social Twitter/X.

- Seis tópicos polarizados: Lula, Bolsonaro, Cloroquina, Vacina, TV Globo e Igreja.

# UstanceBR (Pereira et. al., 2026)

- Modelos supervisionados baseados em *deep learning* exigem grandes massas de dados rotulados, e com classes bem definidas

- Objetivo: produzir um recurso para detecção de posicionamentos com maior número de exemplos extraídos da rede social Twitter/X.

- Seis tópicos polarizados: Lula, Bolsonaro, Cloroquina, Vacina, TV Globo e Igreja.

- Posicionamento pode ser direto (“odeio x”) ou indireto (“a política econômica de x é muito ruim”).

# UstanceBR (Pereira et. al., 2026)

- Modelos supervisionados baseados em *deep learning* exigem grandes massas de dados rotulados, e com classes bem definidas

- Objetivo: produzir um recurso para detecção de posicionamentos com maior número de exemplos extraídos da rede social Twitter/X.

- Seis tópicos polarizados: Lula, Bolsonaro, Cloroquina, Vacina, TV Globo e Igreja.

- Posicionamento pode ser direto (“odeio x”) ou indireto (“a política econômica de x é muito ruim”).

- Córpus inclui também dados textuais (tweets) e não textuais (redes de amigos, seguidores, timelines completas etc.)

# Rotulação

- A partir de uma grande massa de *tweets*, foram selecionadas as mensagens contendo palavras-chave de interesse (e.g., “Lula”, etc.)
    - cerca de 120 k mensagens iniciais por tópico

# Rotulação

- A partir de uma grande massa de *tweets*, foram selecionadas as mensagens contendo palavras-chave de interesse (e.g., “Lula”, etc.)
    - cerca de 120 k mensagens iniciais por tópico
- Mensagens foram avaliadas e rotuladas em esquema binário (a favor ou contrário ao tópico-alvo) e mantidas somente quando indicavam posicionamento inequívoco.

# Rotulação

- A partir de uma grande massa de *tweets*, foram selecionadas as mensagens contendo palavras-chave de interesse (e.g., “Lula”, etc.)
    - cerca de 120 k mensagens iniciais por tópico
- Mensagens foram avaliadas e rotuladas em esquema binário (a favor ou contrário ao tópico-alvo) e mantidas somente quando indicavam posicionamento inequívoco.
- Todas as outras mensagens (cerca de 90% do total, em grande parte factuais) foram descartadas.

# Procedimento

- Cada tópico-alvo foi anotado por um avaliador até obter 4k mensagens em cada classe

# Procedimento

- Cada tópico-alvo foi anotado por um avaliador até obter 4k mensagens em cada classe

- Anotação foi então refeita por um segundo avaliador independente.

# Procedimento

- Cada tópico-alvo foi anotado por um avaliador até obter 4k mensagens em cada classe

- Anotação foi então refeita por um segundo avaliador independente.

- As duas anotações foram comparadas, e somente os casos em que houve concordância foram mantidos.
    - Todos os demais foram descartados

# Procedimento

- Cada tópico-alvo foi anotado por um avaliador até obter 4k mensagens em cada classe

- Anotação foi então refeita por um segundo avaliador independente.

- As duas anotações foram comparadas, e somente os casos em que houve concordância foram mantidos.
    - Todos os demais foram descartados

- Procedimento levou cerca de 6 meses e envolveu 6 anotadores

# Dificuldades de uso da versão inicial (r3)

- Mesmo usuário que tinha um posicionamento sobre um alvo (eg., cloroquina) poderia aparecer em outro subconjunto (eg. Globo)
    - Inviabilizando aprendizado em domínios cruzados

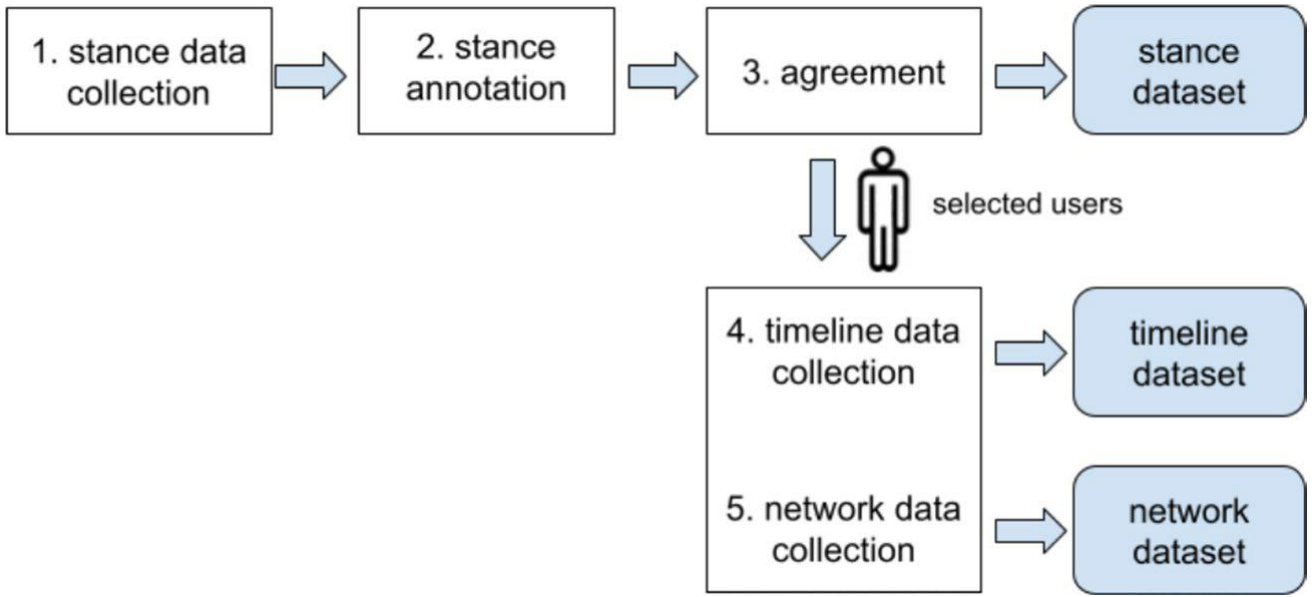
# Dificuldades de uso da versão inicial (r3)

- Mesmo usuário que tinha um posicionamento sobre um alvo (eg., cloroquina) poderia aparecer em outro subconjunto (eg. Globo)
    - Inviabilizando aprendizado em domínios cruzados
- Usuários duplicados foram então eliminados
    - Causando grande desbalanceamento de classes

# Dificuldades de uso da versão inicial (r3)

- Mesmo usuário que tinha um posicionamento sobre um alvo (eg., cloroquina) poderia aparecer em outro subconjunto (eg. Globo)
    - Inviabilizando aprendizado em domínios cruzados
- Usuários duplicados foram então eliminados
    - Causando grande desbalanceamento de classes
- Base de dados foi revisada (r4) e aumentada para restaurar balanceamento e eliminar usuários duplicados

# Base de dados completa (Pereira et. al., 2026)



# Estatísticas descritivas – UstanceBR r4

| Target | Stance text | | | | Network relations | | | Timelines |
|---|---|---|---|---|---|---|---|---|
| | Against instances | For instances | Word total | Words per tweet | Friends per user | Followers per user | Mentions per user | Mean length (tweets) |
| Bolsonaro | 1,700 | 1,700 | 69,997 | 20.59 | 956 | 927 | 1,902 | 2,428 |
| Lula | 1,700 | 1,700 | 71,323 | 20.98 | 891 | 901 | 1,773 | 2,576 |
| Hydrox. | 1,700 | 1,700 | 81,105 | 23.85 | 947 | 890 | 2,501 | 2,108 |
| Sinovac | 1,700 | 1,700 | 79,812 | 23.47 | 948 | 975 | 2,221 | 2,098 |
| Globo TV | 1,700 | 1,700 | 53,998 | 15.88 | 822 | 959 | 1,204 | 2,985 |
| Church | 1,700 | 1,700 | 72,158 | 21.22 | 728 | 919 | 937 | 3,419 |
| Overall | 10,200 | 10,200 | 428,393 | 21.00 | 882 | 928 | 1,756 | 2,602 |

Podemos reduzir estes custos?

# Algumas alternativas possíveis

1. Métodos semi supervisionados

2. Manter rótulos divergentes

*3. Crowd-sourcing*

*4. Destilação de conhecimento*

# 1. Métodos semi supervisionados

- Métodos modernos de classificação de texto permitem a rotulação de grandes massas de dados com menor esforço humano

# 1. Métodos semi supervisionados

- Métodos modernos de classificação de texto permitem a rotulação de grandes massas de dados com menor esforço humano

- Passo 1: humanos anotam um conjunto inicial de exemplos (em volume razoável, representativo do problema, diversificado, balanceado, etc.)

# 1. Métodos semi supervisionados

- Métodos modernos de classificação de texto permitem a rotulação de grandes massas de dados com menor esforço humano

- Passo 1: humanos anotam um conjunto inicial de exemplos (em volume razoável, representativo do problema, diversificado, balanceado, etc.)

- Passo 2: o conjunto anotado é utilizado para treinar um classificador

# 1. Métodos semi supervisionados

- Métodos modernos de classificação de texto permitem a rotulação de grandes massas de dados com menor esforço humano
- Passo 1: humanos anotam um conjunto inicial de exemplos (em volume razoável, representativo do problema, diversificado, balanceado, etc.)
- Passo 2: o conjunto anotado é utilizado para treinar um classificador
- Passo 3: o classificador é aplicado na rotulação da massa de dados completa

# 1. Métodos semi supervisionados

- Métodos modernos de classificação de texto permitem a rotulação de grandes massas de dados com menor esforço humano
- Passo 1: humanos anotam um conjunto inicial de exemplos (em volume razoável, representativo do problema, diversificado, balanceado, etc.)
- Passo 2: o conjunto anotado é utilizado para treinar um classificador
- Passo 3: o classificador é aplicado na rotulação da massa de dados completa
- Passo 4: a acurácia do classificador é medida para garantir que seja semelhante à observada no treino

# 1. Métodos semi supervisionados

- Métodos modernos de classificação de texto permitem a rotulação de grandes massas de dados com menor esforço humano

- Passo 1: humanos anotam um conjunto inicial de exemplos (em volume razoável, representativo do problema, diversificado, balanceado, etc.)

- Passo 2: o conjunto anotado é utilizado para treinar um classificador

- Passo 3: o classificador é aplicado na rotulação da massa de dados completa

- Passo 4: a acurácia do classificador é medida para garantir que seja semelhante à observada no treino

- Passo 5: avaliadores humanos revisam a rotulação automática (revisar rótulos é mais fácil do que decidir quais rótulos atribuir)

# O uso de LLMs

- LLMs passaram a oferecer uma alternativa ágil à rotulação assistida
    - A depender da tarefa, sem exemplos previamente anotados
- Pode ser também um “anotador adicional” na equipe
- Mas algum grau de supervisão humana continua sendo necessária
- Rotular dados usando apenas LLM para então criar um classificador?

# 2. Rótulos divergentes

- Ao invés de tentar alcançar consenso entre anotadores, certas aplicações podem simplesmente **acomodar opiniões divergentes**
- Não havendo verdade absoluta, não há consenso possível
- Conjunto de dados inclui a anotação de todos os participantes, mesmo que sem concordância
- Dados são usados para treinar modelos que refletem a opinião média do grupo de anotadores, ou uma distribuição de opiniões possíveis
- Problemas com esta abordagem?

# 3. *Crowd sourcing*

- Estratégia: criar tarefas em que múltiplos participantes produzem os rótulos
    - sem ter conhecimento explícito do objetivo da tarefa (para evitar viés)
- No exterior conta-se com serviços como Amazon Mechanical Turk, que permitem a coleta de grandes massas de dados mediante remuneração
- No Brasil, contamos com Google Docs e voluntários! ☺

# 4. Destilação do conhecimento

- A definição do problema – representada pelo conjunto de dados rotulado – deveria ter algum grau de supervisão humana
    - Tanto nos textos quanto nos rótulos
- Supervisão humana pode entretanto ser custosa, especialmente se depender de especialistas
- Técnicas modernas de AM, como destilação do conhecimento (*knowledge distillment*) permitem treinar um modelo a partir de um pequeno conjunto de rótulos de alta qualidade e generalizar para um conjunto completo

# BRmoral

# Exemplo: construção do córpus BRmoral (Pavan et. al., 2020)

- Coleção de textos opinativos sobre questões de natureza moral rotulados em uma escala 0=totalmente contra até 5=totalmente a favor

- Premissa: como forma de contornar a necessidade de anotação dos dados por terceiros (custosa, sujeita a erros, problemas de concordância etc.) todos os rótulos são **fornecidos pelos próprios autores dos textos**

> Eu não vejo problema com o porte de armas ser legalizado, porque quem mata são as pessoas, e não as armas sozinhas (se uma pessoa quer matar outra, ela pode conseguir fazer isso de outras formas que não sejam apenas através de armas de fogo).

# Exemplo: construção do córpus BRmoral

> Eu não vejo problema com o porte de armas ser legalizado, porque quem mata são as pessoas, e não as armas sozinhas (se uma pessoa quer matar outra, ela pode conseguir fazer isso de outras formas que não sejam apenas através de armas de fogo).

- Mas então apenas transferimos a responsabilidade de anotação para os autores? Sujeita aos mesmos problemas da anotação por terceiros?
  - Autor precisa julgar o que escreveu e atribuir um escore?
  - Não.

# Anotação pelo próprio autor? Não.

> Eu não vejo problema com o porte de armas ser legalizado, porque quem mata são as pessoas, e não as armas sozinhas (se uma pessoa quer matar outra, ela pode conseguir fazer isso de outras formas que não sejam apenas através de armas de fogo).

Não se trata de anotação. Na construção do córpus em questão, solicitou-se primeiro a opinião numérica (o rótulo 0..5) e **apenas depois disso** um texto de suporte ao que foi informado.

- Ênfase no rótulo (objetivo, livre de ambiguidade) e não no texto (subjetivo, ambíguo)

No exemplo acima, participante tinha opinião “3”, situada imediatamente acima do centro da escala = subjetividade

# Mas os rótulos fornecidos pelos próprios participantes da coleta de dados são melhores?

- Defina “melhor”. ☺

- São certamente mais baratos...
- Mas podem conter ruído

- Mais importante: **opiniões são mais complexas do que escore 0..5**
- Uma possível estratégia de validação seria anotar parte dos dados e comparar a anotação com os rótulos existentes
- Necessidade de medir o grau de concordância entre anotadores e acurácia em relação ao córpus
    - Medida Kappa: 0=nenhuma concordância 1=concordância perfeita

# Exemplo: verificação do córpus BRmoral

- Subconjunto de 3120 textos  (76.6% do total) contendo todas as opiniões dos primeiras 390 participantes da coleta de dados foi manualmente anotado como positivo, negativo ou neutro.
    simplificação da escala 0..5
    seguindo diretrizes bem definidas

- Concordância **média** (medida Kappa) entre anotadores foi de 0.63 (boa).

- Mais alta para opiniões extremas
    (0.76 de concordância para opiniões negativas e 0.74 para positivas)

- Menor para opiniões intermediárias (0.39, ou "razoável")
- Acurácia da anotação em relação aos rótulos do córpus foi de 69%.
- Juntas, concordância e acurácia sugerem um conjunto de dados de boa qualidade.

# Quando a anotação não funciona

- Esquemas de anotação mal definidos, regras confusas etc. podem ocasionar baixa concordância entre anotadores
- Rótulos de baixa qualidade produzem modelos de baixa qualidade
  - Não espere que seu modelo faça milagres!
- Solução para reduzir o nível de ruído pode ser simplesmente coletar mais dados
  - Em grandes volumes de dados, ruído tende a se dissipar

b5-post

# Exemplo: córpus b5-post (Ramos et. al, 2018)

- Textos Facebook rotulados com cinco escores representando as dimensões de personalidade de seus autores (calculados a partir de questionários)

Uma amiga super especial , que quero ter sempre por perto ! !
Te desejo tudo de melhor ! Muita saúde , sucesso , amor e
Infelizmente não poderemos comemorar hoje , mas não podemos deixar passar em branco ! !
Te adoro ! ! Marcamos algo assim que melhorar "
Adorei o presente $NAME$ $NAME$ $NAME$
Selfie com o troféu
Momento feliz ! Parabéns time ! Por tantas conquistas grandes sacadas de marketing
Partiu premiação ! grandes sacadas de marketing $NAME$ somos incríveis $NAME$ $NUMBER$

Extroversão=3,88 Agradabilidade=3,78 Conscienciosidade=4,33
Neuroticismo=3 Abertura à experiência=4,4

# Exemplo: córpus b5-post (Ramos et. al, 2018)

- Problema: usuários anônimos responderam questionários de personalidade sem supervisão = qualidade dos dados variável

- Resultado: tarefa de classificação é extremamente difícil, e não foi possível atingir os níveis de acurácia observados em outros conjuntos de dados
    - Ruído está nos rótulos de classes, e não necessariamente nos textos

- Possíveis soluções?

# Nota sobre privacidade

# Privacidade e permissão de uso dos dados

- Uso de dados textuais produzidos por terceiros (clientes, alunos etc.) deve ser feito com todo cuidado
- Na pesquisa científica há um protocolo específico a ser seguido
    - Termo de consentimento especificando como vai ser usado
    - Questão da remuneração é controversa e frequentemente proibida
- Se for para uso comercial é mais problemático ainda
    - Empresa deve assegurar-se de que é proprietária dos dados
- Normalmente não é permitido identificar o autor ou individualizá-lo de qualquer forma
    - Métodos de anonimização para nomes próprios, datas, valores etc.

# Parte 2: avaliação, métricas e *baselines*

# Como saber se o modelo é “bom”?

- Desempenho observado na fase de desenvolvimento precisa ser minimamente aceitável
    - Caso contrário, houve *underfitting*
- E na validação?
    - Desempenho inferior ao observado no treinamento: *overfitting*
- Em ambos os casos, isso significa que o modelo não funciona

# Avaliação do modelo

- Modelo precisa atingir um patamar mínimo de desempenho
  - Acurácia, media F1 etc.
- Mínimo é ao menos em parte ditado pela aplicação
  - e.g., o modelo precisa ter acurácia mínima de n% para que seja útil
- Toma-se também modelos de *baseline* por referência
  - e.g., o modelo precisa tomar decisões mais corretas do que o *baseline* aleatório
  - na prática considera-se termos de comparação mais robustos

# Sistemas de *baseline*

- Desempenho que o modelo precisa necessariamente superar
  - Sistemas ou métodos pré-existentes que desejamos automatiza/substituir
  - Decisões baseadas em heurísticas simples
  - Desempenho humano na mesma tarefa
- Precisa ser robusto e convincente
  - Caso contrário a construção do modelo não é justificada
- Frequentemente explora a distribuição de classes (*baseline* de classe majoritária etc.) mas deve ser melhor do que isso sempre que possível

# Discussão: quais os sistemas de *baseline* adequados para estas aplicações?

1. Sistema de FAQ: respostas automáticas a perguntas do usuário

2. Identificação da faixa etária de usuário com base no texto que ele/a produz

Obrigado