Análise de características e erros de classificação

Ivandré Paraboni
EACH – USP

Visão geral

1. Interpretação de modelos de AM
2. Interpretação de modelos textuais
3. Prática
4. Análise de erros

Interpretação de modelos de AM

A necessidade de Interpretação

- Objetivo fundamental de um modelo de AM é o de obter os melhores resultados possíveis de acordo com alguma métrica de desempenho de interesse (acurácia, F1 etc.)

A necessidade de Interpretação

- Objetivo fundamental de um modelo de AM é o de obter os melhores resultados possíveis de acordo com alguma métrica de desempenho de interesse (acurácia, F1 etc.)
- Modernamente, entretanto, é cada vez mais comum a exigência de explicar as decisões tomadas pelo modelo.

- Por quê?

Exemplos

- Pré-seleção de candidatos a uma vaga de trabalho
- Reconhecimento facial para detecção de atividades suspeitas
- Análise de crédito

Exemplos

- Pré-seleção de candidatos a uma vaga de trabalho
- Reconhecimento facial para detecção de atividades suspeitas
- Análise de crédito

- À medida que a automação avança, a sociedade contemporânea passa a exigir cada vez mais controle e transparência sobre estas soluções.

    - Risco à vida, dano pessoal, prejuízo financeiro etc.

Interpretação e *overfitting*

- O sobreajuste (*overfitting*) é a incapacidade de generalização do modelo diante de novas instâncias do problema.
- A Interpretação em tempo de desenvolvimento ajuda a evitar este tipo de viés
    - e.g., eliminando-se características muito específicas etc.

Interpretação de AM

- Global: quais as características que o modelo utiliza na tomada de decisão?
- Local: o que faz uma instância específica receber um determinado rótulo?

Global versus Local

- Ambas as formas de Interpretação são de interesse da aplicação
  - Global: quais os fatores que levam um modelo a distinguir atividades normais de suspeitas, conceder ou não uma linha de crédito etc.
  - Local: por que o indivíduo x foi classificado como suspeito? Por que um indivíduo y não teve crédito aprovado?
- Mas são também de interesse do desenvolvedor
  - Para evitar injustiças / decisões distorcidas etc.
  - Para melhor ajustar o modelo

Exemplo

- Seja um modelo de classificação de indivíduos como depressivos ou não a partir de dados textuais (e.g., de redes sociais)

Exemplo

- Seja um modelo de classificação de indivíduos como depressivos ou não a partir de dados textuais (e.g., de redes sociais)

- Interpretação **global** pode nos fornecer indicadores do bom ou mau funcionamento do modelo:
  - Uso de pronomes de primeira pessoa, palavras de conotação negativa etc.
  - Palavras espúrias, ruído, código html etc.

Exemplo

- Seja um modelo de classificação de indivíduos como depressivos ou não a partir de dados textuais (e.g., de redes sociais)

- Interpretação **local** pode nos ajudar a entender porque o modelo se comporta de forma inesperada em certos casos:
  - Uso de pronomes de primeira pessoa, palavras de conotação negativa etc.
  - Palavras espúrias, ruído, código html etc.

Interpretação baseada em características

- Objetivo é identificar as características que desempenham papel global ou local na tarefa de aprendizado

- Modelos criados a partir de **engenharia de características** tendem a ser facilmente explicáveis
    - características possuem um sentido concreto e bem conhecido

- Modelos **orientados a dados** podem ser menos interpretáveis
    - A depender do tipo de dado que constitui as características

Interpretação de modelos textuais

Características textuais

- Modelos baseados em palavras são razoavelmente interpretáveis
  - Apesar do grande volume de características

Características textuais

- Modelos baseados em palavras são razoavelmente interpretáveis
    - Apesar do grande volume de características
- Meta-características textuais, como categorias LIWC, são melhores ainda

Características textuais

- Modelos baseados em palavras são razoavelmente interpretáveis
    - Apesar do grande volume de características
- Meta-características textuais, como categorias LIWC, são melhores ainda

- Em menor grau, modelos de n-gramas de palavras ou de n-gramas de caracteres também

Características textuais

- Modelos baseados em palavras são razoavelmente interpretáveis
    - Apesar do grande volume de características
- Meta-características textuais, como categorias LIWC, são melhores ainda
- Em menor grau, modelos de n-gramas de palavras ou de n-gramas de caracteres também
- Já modelos que usam representações próprias (e.g., em uma rede neural) tendem a limitar ou eliminar esta possibilidade.

Alternativa simples

- Se o modelo desenvolvido não é passível de interpretação, ainda assim pode ser útil criar um modelo de apoio que seja mais explicável
    - (e.g., RegLog baseada em palavras)
- Obviamente não são a mesma coisa, mas o modelo de apoio pode auxiliar no refinamento do modelo principal, e na identificação de problemas.

3. Prática

A biblioteca Eli5

- Implementa métodos de interpretação global e local de classificadores e regressores textuais lineares do scikitlearn.
    - É necessário que haja um mapeamento direto entre características e os coeficientes do classificador
- Computa a importância relativa de cada característica (e.g., cada palavra) por permutação.
- Resultado é um *ranking* das características mais importantes para aquele modelo.

Uso

- Basta ter um classificador compatível já treinado, e um vetor com os nomes das características (e.g., categorias LIWC, vocabulário de um *vectorizer* etc.)

- Dois métodos básicos:

- **eli5.show_weights**: Interpretação global do classificador, retornando a importância relativa das N melhores característica

- **eli5.show_predictions**: Interpretação local de uma instância específica

- Tutorial completo (e muito simples) em https://eli5.readthedocs.io/en/latest/tutorials/sklearn-text.html

Interpretação global de um classificador de texto

```
eli5.show_weights(clf, vec=vec, top=10,
                  target_names=twenty_test.target_names)
```

y=alt.atheism top features		y=comp.graphics top features		y=sci.med top features		y=soc.religion.christian top features	
Weight?	Feature	Weight?	Feature	Weight?	Feature	Weight?	Feature
+1.991	mathew	+1.702	graphics	+2.016	pitt	+1.193	rutgers
+1.925	keith	+0.825	images	+1.951	doctor	+1.030	church
+1.834	atheism	+0.798	files	+1.758	information	+1.021	christians
+1.813	okcforum	+0.786	software	+1.697	disease	+0.946	clh
+1.697	go	+0.779	file	+1.655	treatment	+0.899	christ
+1.696	psuvm	+0.773	image	+1.522	msg	+0.797	christian
+1.617	believing	+0.729	package	+1.518	health	*... 11122 more positive ...*	
+1.594	psu	+0.724	card	*... 15007 more positive ...*		*... 24657 more negative ...*	
... 10174 more positive ...		+0.702	3d	*... 20772 more negative ...*		-0.852	graphics
... 25605 more negative ...		*... 11710 more positive ...*		-1.764	god	-0.894	posting
-1.686	rutgers	*... 24069 more negative ...*		-2.171	graphics	-1.181	nntp
-10.453	<BIAS>	-1.379	<BIAS>	-5.013	<BIAS>	-1.243	host

Interpretação local de uma instância classificada

```
eli5.show_prediction(clf, twenty_test.data[0], vec=vec,
                     target_names=twenty_test.target_names)
```

y=alt.atheism (probability **0.000**, score **-8.709**) top features

Contribution?	Feature
+1.743	Highlighted in text (sum)
-10.453	<BIAS>

from: brian@ucsd.edu (brian kantor) subject: re: help for kidney stones ..... organization: the avant-garde of the now, ltd. lines: 12 nntp-posting-host: ucsd.edu as i recall from my bout with kidney stones, there isn't any medication that can do anything about them except relieve the pain. either they pass, or they have to be broken up with sound, or they have to be extracted surgically. when i was in, the x-ray tech happened to mention that she'd had kidney stones and children, and the childbirth hurt less. demerol worked, although i nearly got arrested on my way home when i barfed all over the police car parked just outside the er. - brian

Classificadores não suportados

- Obter coeficientes, associar aos nomes de features e exibir em formato html é essencialmente uma tarefa de *debugging*

- Modelos mais complexos podem ser interpretados com uso de métodos mais poderosos como Lime (Ribeiro et. al., 2016)

    - Classe **TextExplainer** na biblioteca Eli5

A importância da análise de características

- Contexto: classificador de artigos de notícias de acordo com o tópico (cadernos da FSP) como política, ciência, economia, etc.

- Resultado obtido: 100% de acurácia em todos os cenários, incluindo validação cruzada, uso de diferentes conjuntos de teste, etc.

- O que está acontecendo aqui?

Interpretação global – notícias políticas

y=for top features

Weight	Feature
+7.512	poder
+3.899	presidente
... 3312 more positive ...	
... 3580 more negative ...	
-1.998	viagem
-2.049	restaurante

Interpretação local

y=for (probability **0.653**, score **0.630**) top features

Contribution?	Feature
+0.591	Highlighted in text (sum)
+0.039	<BIAS>

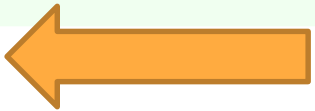
Lula está livre poder

Interpretação local

y=for (probability **0.653**, score **0.630**) top features

Contribution[?]	Feature
+0.591	Highlighted in text (sum)
+0.039	<BIAS>

Lula está livre poder



Os textos tinham ao final um marcador indicativo do caderno do jornal (Poder, Economia, Ciência, etc.)

Exemplos

i. Personalidade MBTI

Personalidade MBTI (dos Santos & Paraboni, 2022)

- Objetivo: Interpretação global e local
- Modelo real baseado em BERT não era interpretável
- Modelo de apoio criado usando regressão logística sob BoW de palavras (TF-IDF)

Interpretação global: extroversão x introversão

Weight	EI
+0.113	job
+0.097	may
+0.090	never
+0.086	them
+0.084	free
+0.081	im
+0.080	aren
+0.076	10
+0.073	couple
+0.073	wiki

...	...
-0.058	comcast
-0.058	temple
-0.059	death
-0.061	est
-0.062	city
-0.062	vs
-0.062	week
-0.062	usually
-0.062	own
-0.062	album

Extroversão (acima) e introversão (abaixo)

that's because it's done as a team, and there are others higher up than him. do we really think that a technology that threatens the world's largest and most blood-thirsty banking cartels can't fund these activities? yes.

i personally want to see santa hat baron if you have 2 or more christmas skins in a game. same in my game except it's the dancing plague. i keep getting those global events every 6 months.

ii. Fundamentos morais

Fundamentos morais (Lan & Paraboni, 2022)

- Objetivo: Interpretação global
- Modelo real baseado em BERT não era interpretável
- Modelo de apoio de bom resultado baseado em n-gramas de caracteres
- Ainda não é facilmente interpretável
    - mas pode ser acrescido de exemplos de uso

	Increased feature importance		Decreased feature importance	
	weight	ngram	weight	ngram
Care/Harm	+6.843	a rapi	−3.919	a kille
	+6.798	ace if	−3.813	again c
	+6.381	a prc	−3.777	am m
	+6.289	allis	−3.718	affin
	+6.279	a fuc	−3.674	a day k
	+6.049	allies	−3.275	absolut
	+6.011	am for	−3.213	a murde
	+5.886	a batt	−3.142	acros
	+5.868	a baby	−3.139	a picks
	+5.696	a skin	−3.127	a cent

	Increased feature importance			Decreased feature importance		
	weight	ngram	example	weight	ngram	example
Care/Harm	+6.843	a rapi	OMFG HE'S A RAPIST	−3.919	a kille	MILITIA KILLED ATTACKED
	+6.798	ace if	the Storm We ll Face if Romney	−3.813	again c	we meet again can't wait
	+6.381	a prc	Uighur Jihadis: they're not just a PRC	−3.777	am m	Mainstream Media not reporting
	+6.289	allis	you ain't six bitch"" – Allisons Mom	−3.718	affin	I have 150 day boosters on affinity
	+6.279	a fuc	I can never give a fuck	−3.674	a day k	A pussy a day keeps the devil away
	+6.049	allies	defend themselves at his rallies	−3.275	absolut	Absolute morons protesting
	+6.011	am for	I am for peace!	−3.213	a murde	you're a coward and a murderer
	+5.886	a batt	Saddened to see … into a battle	−3.142	acros	extreme devastation across Bethesda
	+5.868	a baby	punished for not having a baby	−3.139	a picks	Stay calm rock a Picks For Peace
	+5.696	a skin	a sin problem, not a skin problem	−3.127	a cent	suffered terrorism for well over a century

iii. Saúde mental

Transtorno de ansiedade (dos Santos et. al, 2024)

- Objetivo: Interpretação global e local *aqui não discutida
- Modelo real baseado em BERT não era interpretável
- Modelos de apoio criados usando regressão logística sob palavras (TF-IDF) e categorias LIWC

Transtorno de ansiedade (palavras)

Weight[?]	Feature
+8.946	ansiedade
+5.301	remédio
+3.508	psiquiatra
+3.481	lt
+3.395	hoje
+3.393	psicóloga
+3.319	terapia
+3.187	bbb
+3.161	depressão
+2.913	crise
+2.567	remédios
+2.492	covid
+2.472	me
+2.439	floriano
+2.312	tomar
+2.245	por
... 3226 more positive ...	
... 3755 more negative ...	
-2.560	pergunte
-2.609	vai
-2.737	você
-3.159	<BIAS>

Depressão (LIWC)

Weight[?]	Feature
+5.247	liwc4_i
+3.170	liwc33_cogmech
+3.045	liwc1_funct
+2.135	liwc40_incl
+2.049	liwc18_conj
+1.987	liwc37_tentat
+1.956	liwc26_humans
+1.900	liwc34_insight
+1.595	liwc46_bio
+1.303	liwc54_time
+1.274	liwc11_verb
... 22 more positive ...	
... 15 more negative ...	
-1.099	liwc10_article
-1.201	liwc27_affect
-1.449	liwc23_social
-1.518	liwc19_negate
-1.761	liwc53_space
-2.196	<BIAS>
-2.718	liwc6_you
-3.768	liwc7_shehe
-3.932	liwc9_ipron

Para pensar...

Considerações

- A Interpretação do modelo pode revelar características surpreendentes – tanto no sentido positivo como negativo

- Parte do comportamento negativo é esperado – afinal, é um reflexo do conjunto de dados de treino que foi utilizado
    - Se for representativo do uso real do modelo, não é um problema

- Uma maior frequência de qualquer característica (e.g., palavra) em determinada classe sempre pode enviesar o resultado

É possível contornar este tipo de viés?

Em parte...

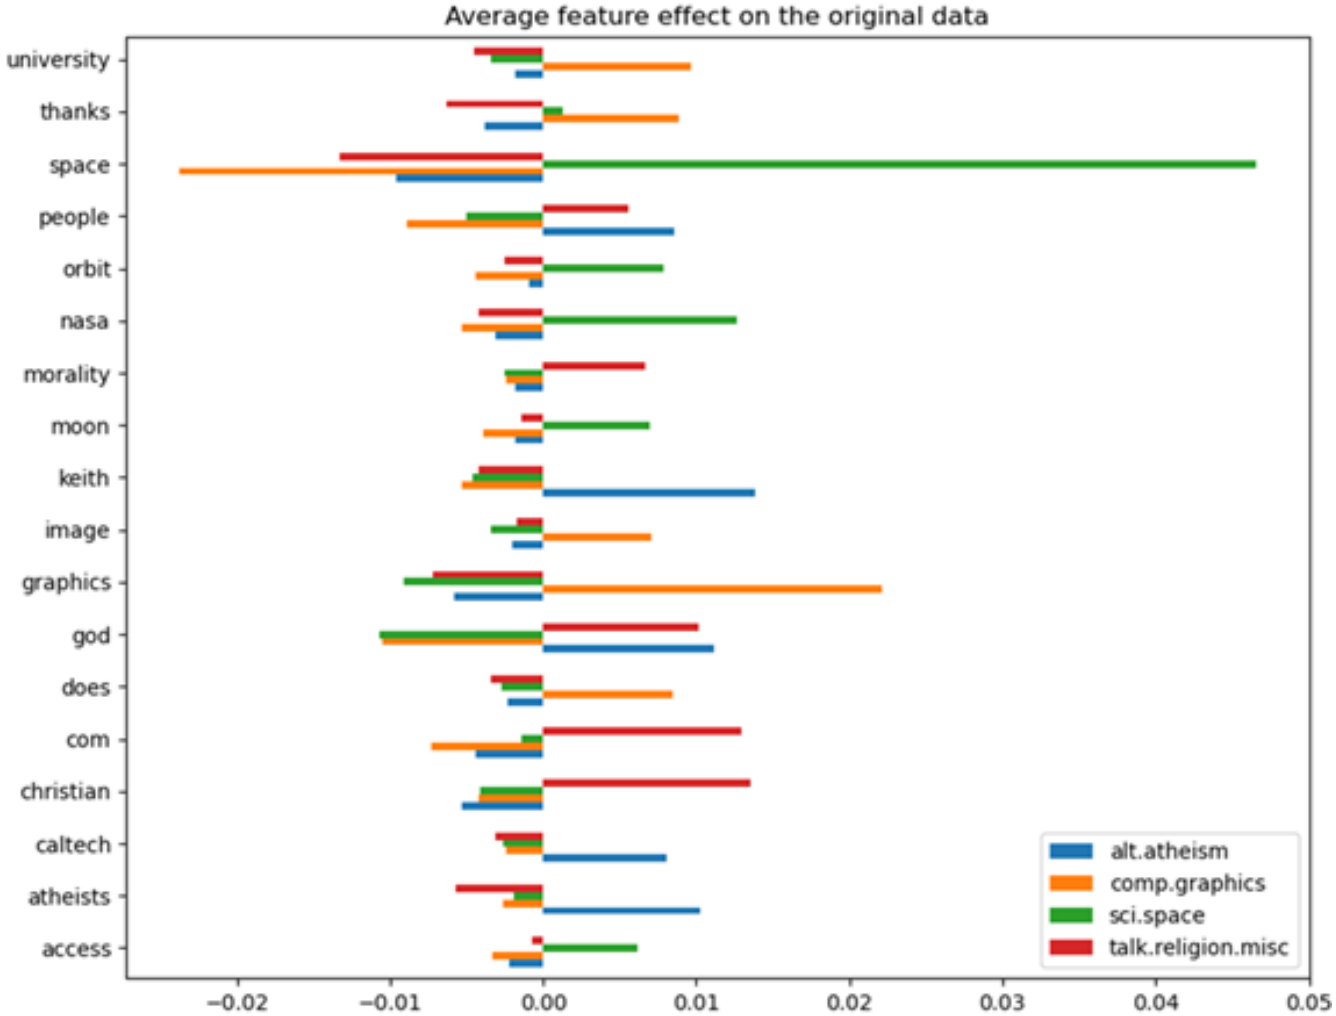
- Mas evitar totalmente estas “distorções” implicaria na construção de conjuntos “balanceados” com a mesma frequência de palavras em cada classe! ☺

Visualização de *features* no scikit-learn

Visualização de *features* no scikit-learn

- Biblioteca inclui alguns recursos de visualização de *features* com base nos coeficientes aprendidos ponderados por frequência

- https://scikit-learn.org/stable/auto_examples/text/plot_document_classification_20newsgroups.html


Average feature effect on the original data
university
thanks
space
people
orbit
nasa
morality
moon
keith
image
graphics
god
does
com
christian
caltech
atheists
access
−0.02
−0.01
0.00
0.01
0.02
0.03
0.04
0.05
alt.atheism
comp.graphics
sci.space
talk.religion.misc

Análise de erros

Como melhorar o modelo?

- A interpretação do modelo oferece ferramentas para a definição mais precisa das características de aprendizado

- Mas e se as características parecem corretas, e o modelo continua tendo baixo desempenho?

➔ análise de erros

Verifique seus resultados

- Uma análise visual das instâncias classificadas incorretamente pode oferecer insights do porquê do problema

- Objetivo é identificar classes de problemas – começando pelas mais expressivas
  - Instâncias difíceis de julgar/classificar
  - Problemas de rotulação / definição do problema
  - Necessidade de características adicionais

Quando o problema é muito difícil

- Casos sem solução aparente podem indicar uma tarefa computacional mal definida
    - Exemplo: posicionamentos favoráveis desfavoráveis / NA

- Uma boa maneira de verificar isso é fazendo uso de avaliadores humanos

- **Avaliação humana** pode também servir para ilustrar a complexidade do projeto (e justificar sua execução ou não)

Um exemplo no domínio da saúde mental

Avaliação por especialistas (dos Santos et. al., 2025)

- Contexto: modelo de predição de depressão e transtorno de ansiedade em redes sociais X e Reddit (dos Santos et. al., 2025)

- Resultado para X / depressão: F1 = 0,69

- Questão: as decisões do modelo fazem sentido do ponto de vista clínico?

Experimento

- Tarefa: classificação binária de timelines do X (172 mil *tweets*) como indicativas de depressão ou não

- Seleção aleatória de 100 instâncias de teste, divididas por erro de classificação (VP, FP, VN, FP).

- Objetivo era o de avaliar o modelo, não os especialistas.

Tarefa

- Grupo de 7 especialistas em saúde mental e um supervisor com formação em psicologia foi solicitado a avaliar os dados e decidir se cada *timeline* era indicativa de um indivíduo com depressão ou não.

- Instrução espelhava o *prompt* usado no próprio modelo (que por sua vez era derivado da literatura médica).
    - Porém com uma opção intermediária (sem base para julgar)

Resultados

- Acurácia do modelo foi muito próxima das acurácia dos especialistas
    - Ou até superior se descartada a classe intermediária

Resultados

- Acurácia do modelo foi muito próxima das acurácia dos especialistas
    - Ou até superior se descartada a classe intermediária
- Entretanto, a concordância Kappa entre modelo e especialistas foi apenas moderada (0,56).
- Ou seja: modelo e especialistas fazem escolhas distintas, embora com o mesmo resultado médio.

Quem está certo?

Considerações

Tanto o desempenho do modelo quanto a análise dos especialistas possuem limitações.

- Analisar redes sociais não é uma tarefa típica de psicólogos
- O texto não possui informação completa sobre o problema
- Juízes humanos tinham acesso ao conjunto completo de publicações de cada indivíduo, enquanto o modelo, por razões de custo computacional, faz apenas uma amostragem aleatória de um pequeno conjunto de postagens cada usuário.

- Avaliação humana realizada serviu para ilustrar os limites do modelo desenvolvido e da própria tarefa.

Obrigado