Significância estatística e ablação

Ivandré Paraboni
EACH - USP

Visão geral

1. Significância estatística e ablação

2. Exemplo: detecção de discurso de ódio e viés político

Comparando múltiplas soluções alternativas

Como saber se um modelo é realmente melhor?

- Projeto de soluções baseadas em AM normalmente produz um grande número de modelos alternativos
- Resultados podem ser muito próximos
- É importante lembrar que os resultados de validação é um retrato do conjunto de dados atual, com viés, ruído, etc.
    - Podem ser fruto da sorte (ou azar) do desenvolvedor = são os resultados daquele conjunto
    - Diferente do uso real do modelo usando outros dados

Um resultado real ou obra do acaso?

- Métodos como validação cruzada, aliados a um conjunto de dados de qualidade, minimizam as chances de um resultado espúrio.

- Resultado observado é apenas uma estimativa **média**, e há sempre uma margem de erro.

- Assim, dois modelos de resultados muito próximos podem, na prática, ser estatisticamente similares.

    - E neste caso a escolha deveria recair sobre o modelo de menor custo, mesmo que pareça ter desempenho numericamente inferior (no conjunto de desenvolvimento).

Significância estatística

- Diversos tipos de testes estatísticos permitem avaliar, com um determinado valor de confiança, se dois conjuntos de resultados são significativamente distintos, ou se a diferença observada não pode ser atribuída ao desempenho de um modelo (ou seja, se é mera obra do acaso).

- Ferramentas deste tipo podem assim ser usadas para saber se a vantagem de um modelo A sobre um modelo B é real ou não.

- Uma forma simples de comparar as taxas de erro em dois conjuntos de predições é o teste de McNemar.

Teste de McNemar

- Objetivo: comparar dois modelos A e B verificando se a diferença entre suas predições é ou não estatisticamente significativa.

- Entrada: matriz de contingência 2 x 2 representando a quantidade de erros e acertos dos modelos A e B:

	B correto	**B errado**
A correto	n_{11}	n_{10}
A errado	n_{01}	n_{00}

- Saída: p-valor que indica a significância observada.

Matriz de contingência

- Gerada facilmente a partir dos vetores de predições dos dois modelos.

    1. Nos dois vetores, substitui-se cada predição por um valor binário indicando erro (o) ou acerto (1).

    2. Os vetores de erros/acertos são então comparados, computando-se as quatro contagens da matriz de contingência.

- A matriz 2x2 resultante é a entrada para o teste de McNemar, disponível em Python e outras linguagens.

Script exemplo

```
# -*- coding: utf-8 -*-
import pandas as pd
from statsmodels.stats.contingency_tables import mcnemar

def main_mcnemar():

    table = [
          [cell_11, cell_12],
          [cell_21, cell_22]
         ]

  if cell_11<25 or cell_12<25 or cell_21<25 or cell_22<25:
     result = mcnemar(table, exact=True)
  else:
     result = mcnemar(table, exact=False, correction=True)
```

```
print('stat=%.3f, p=%.7f' % (result.statistic,result.pvalue),end='')

  significant = False
  for alpha in [0.001, 0.01, 0.05]:
     if result.pvalue < alpha:
        print(' p<' + str(alpha))
        significant = True
        break
  if not significant:
     print(' not significant')
```

Significância estatística no EP2

O que fazer

- Além do exercício normal, gerando resultados com base no conjunto teste2, é solicitado comparar o novo modelo com o do EP1

- Para isso, foi fornecido agora o conjunto teste1 rotulado

- A tarefa consiste em comparar os resultados do teste1 anterior com os resultados do novo modelo com base neste mesmo conjunto

- Esta comparação permite calcular a estatística de McNemar, e é independente do resultado do EP1 sobre o conjunto teste2.

Testes de ablação

Além da comparação de modelos completos

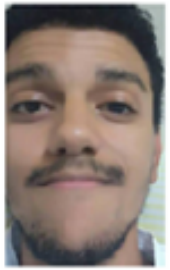
- Arquiteturas mais complexas podem conter múltiplos componentes que contribuem para a solução final
    - e.g., módulos especialistas em uma arquitetura MoE
- Alguns módulos podem ser responsáveis por grande parte da solução, e outros talvez tenham contribuição nula (ou estatisticamente não significativa)
- É do interesse do desenvolvedor implementar a configuração mais eficiente possível
    - Que tenha o desempenho máximo com o menor número de módulos possível

Ablação

- Em um sistema com vários componentes ou recursos, a ablação consiste em testar de forma sistemática todas as configurações possíveis para decidir quais devem ser de fato mantidas na arquitetura final.
    - Recursos são ativados/desativados e o desempenho global é reavaliado.
- A simples medida de desempenho (e.g., acurácia) já permite identificar recursos desnecessários.
    - E se aliada a um teste de significância estatística, é possível obter um alto grau de confiança sobre qual a configuração ótima.

Detecção de discurso de ódio

Créditos



Samuel C Silva

Samuel Caetano da Silva, Thiago Castro Ferreira, Ricelli Moreira Silva Ramos, Ivandré Paraboni (2020) **Data-Driven and Psycholinguistics-Motivated Approaches to Hate Speech Detection**.

Samuel Caetano da Silva (2021) **Detecção de polarização e ideologia política em textos usando modelos neurais e conhecimento heterogêneo**.

Problema

- Plataformas com conteúdo gerado por usuários são suscetíveis a abusos por partes dos próprios usuários ou de terceiros (e.g., hackers)
    - Discurso de ódio, preconceito, discriminação, ofensas etc.

- Coibir estas práticas – preferencialmente de forma automática – tem não apenas uma função social, mas também econômica

Em termos computacionais

- Dado um conjunto de exemplos rotulados (ofensivo / não ofensivo), implementar um classificador de textos
- Análogo a análise de sentimentos?
- Forte componente lexical (palavras indicativas de ofensa)
- Mas formas mais sofisticadas de discurso de ódio exigem modelos igualmente aptos
    - “Sempre lutou contra a balança...”

Tarefas de classificação

- Rótulos indicativos de linguagem abusiva direcionada a dois grupos (mulheres e imigrantes)

- Três tarefas de classificação binária:
  - Uso de linguagem ofensiva (sim ou não)
  - Uso de linguagem agressiva (sim / não)
  - Tipo de alvo (individual ou coletiva)

Exemplos

Exemplos

Linguagem ofensiva:

#Refugees go home (ofensivo)

iMMIGRANT SONG ! (não ofensivo)

Exemplos

Linguagem ofensiva:

#Refugees go home (ofensivo)

iMMIGRANT SONG ! (não ofensivo)

Aggressividade:

Bad girls get spankings (ofensivo, agressivo)

Good girls send nudes (ofensivo,não agressivo)

Exemplos

Linguagem ofensiva:

#Refugees go home (ofensivo)

iMMIGRANT SONG ! (não ofensivo)

Aggressividade:

Bad girls get spankings (ofensivo, agressivo)

Good girls send nudes (ofensivo,não agressivo)

Tipo de alvo:

THIS.#IllegalAliens (ofensivo para um grupo em geral)

Stupid Skank ! (ofensivo para um indivíduo específico).

Conjuntos de dados

- Córpus HatEval (Basile et. al., 2019)

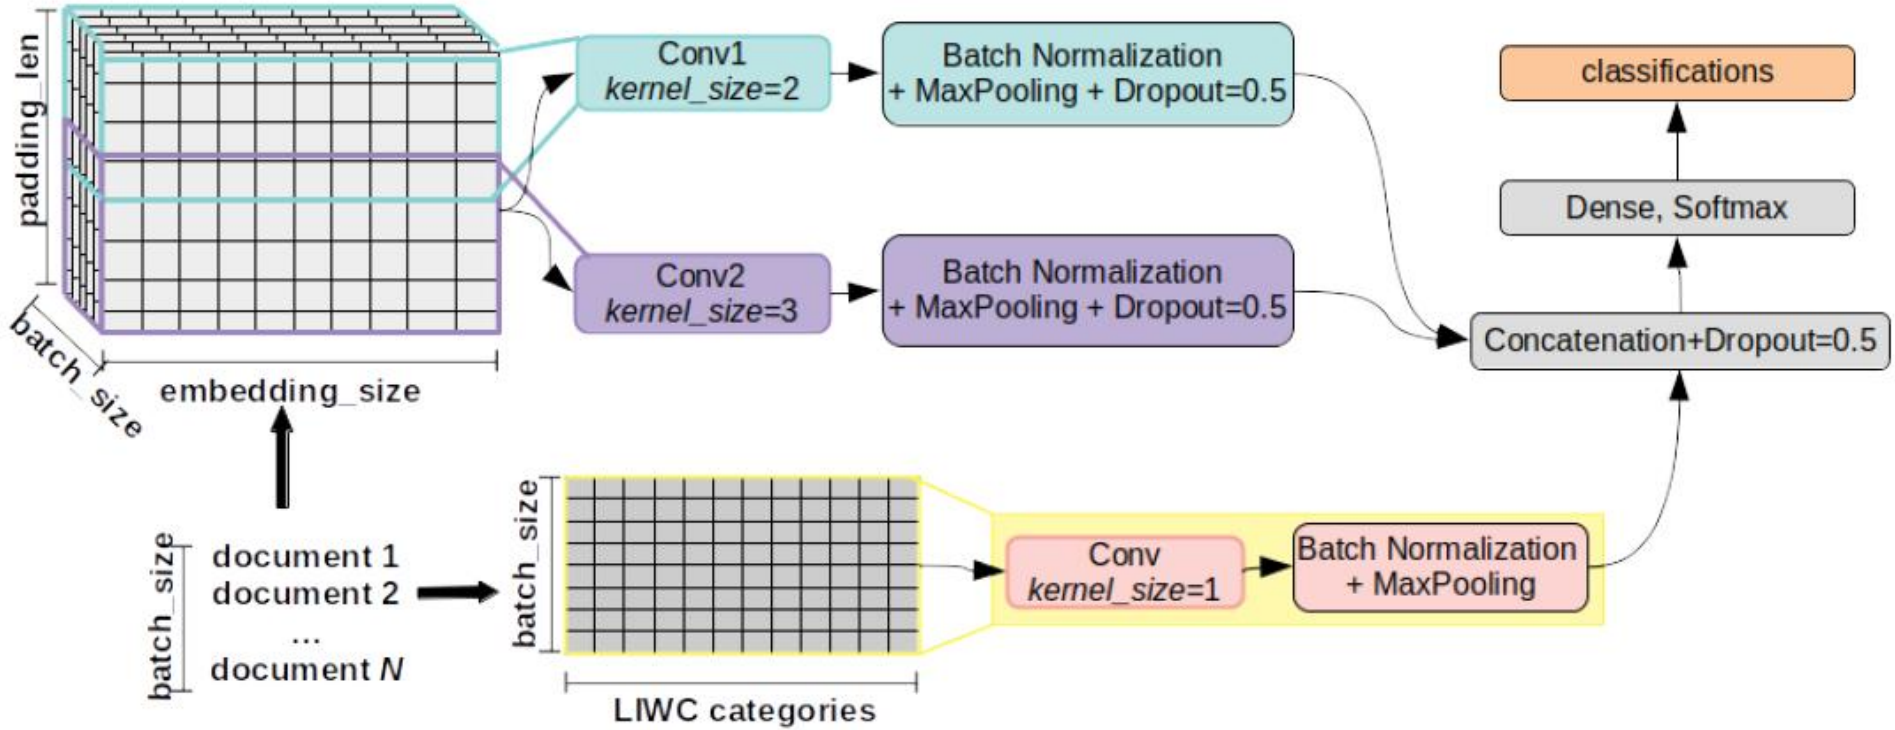
- Distribuído em conjuntos de treino e (posteriormente) teste fixos como parte de uma competição de sistemas de detecção de discurso de ódio

- 19.600 tweets (13.000 em inglês e 6.600 em espanhol) rotulados com informações relativas ao uso de linguagem ofensiva

Estratégias consideradas

Model name	Method	Features
BERT-En/Sp	BERT-base	cased words
CNN.glove+liwc	CNN	word embeddings + LIWC
LR.LIWC	log.regression	LIWC word counts
LR.char	log.regression	TF-IDF character n-grams
LR.word	log.regression	TF-IDF word n-grams
Majority	majority class	na

Classificação de sequências de texto + propriedades psicolinguísticas (LIWC)



Resultados – Espanhol (f1)

Model	Hate speech	Aggressiveness	Target group	Mean
Majority	0.37	0.41	0.42	0.40
LR.char	0.65	0.60	0.71	0.65
LR.word	0.67	0.66	0.74	0.69
LR.liwc	0.60	0.65	0.69	0.65
CNN.glove+liwc	0.50	**0.83**	0.81	0.71
BERT-Sp	0.73	**0.83**	**0.93**	**0.83**
HatEval best	**0.76**	0.82	0.76	0.78

Resultados – Inglês (f1)

Model	Hate speech	Aggressiveness	Target group	Mean
Majority	0.37	0.44	0.45	0.42
LR.char	0.37	0.39	0.63	0.46
LR.word	0.39	0.39	0.64	0.47
LR.liwc	0.49	0.48	0.64	0.54
CNN.glove+liwc	**0.60**	0.59	0.82	0.67
BERT-En	0.53	0.68	**0.85**	**0.69**
HatEval best	**0.60**	**0.75**	0.62	0.66

Detecção de viés político

Material extraído de Samuel Caetano da Silva “Detecção de polarização e ideologia política em textos usando modelos neurais e conhecimento heterogêneo”.
Universidade de São Paulo, 2021.

Problema

- Veículos de imprensa e Indivíduos expressam uma ampla gama de informações de natureza **política**
    - Preferências, ideologias, intenções de voto etc.

- Conhecer estas preferências possui inúmeras aplicações práticas de interesse social, econômico etc.

- Fenômenos podem ser estudados sob a ótica (1) textual (extrair o significado de uma mensagem) ou (2) autoral (identificar a visão política do indivíduo que escreveu a mensagem)
- Tarefa (1) é análogo à análise de sentimentos / posicionamentos
- Tarefa (2) é uma forma de caracterização autoral

Em termos computacionais

- Métodos supervisionados similares aos utilizados em outras tarefas (como discurso de ódio)

- Componente lexical ainda é importante (e.g., “petralha”, “minion” etc.) mas não é suficiente

    - E certos domínios podem ser relativamente neutros neste sentido

Tarefas de classificação

- **Detecção de hiperpartidarismo** ou viés extremado em notícias em inglês (hiperpartidário x neutro) de nível textual e autoral (2 tarefas)

- **Detecção de ideologia política** (sem intenção explícita de convencer) em opiniões de natureza moral (legalização do aborto, porte de armas etc.) em português (esquerda, centro, direita) de nível textual e autoral, ambos em versão binária e ternária (2 x 2 = 4 tarefas)

- **Detecção de alinhamento ideológico** no Twitter em português (favorável ou contrário ao governo federal) (1 tarefa)

Conjuntos de dados

- Detecção de notícias hiperpartidárias: córpus SemEval-2019 task 4 (Kiesel et. al., 2019), com dois conjuntos em inglês:
  - by-articles (rotulação em nível de documento, 645 documentos)
  - by-publisher (rotulação em nível de veículo, 715.000 documentos)
- Detecção de ideologia: córpus BRmoral (Pavan et. al., 2020), com dois conjuntos em português:
  - BRmoral_opiniões (rotulação de opinião liberal/neutra/conservadora, 4000+ documentos)
    BRmoral_usuários (rotulação do indivíduo esquerda/centro/direita, 4000+ documentos)

Conjuntos de dados (cont.)

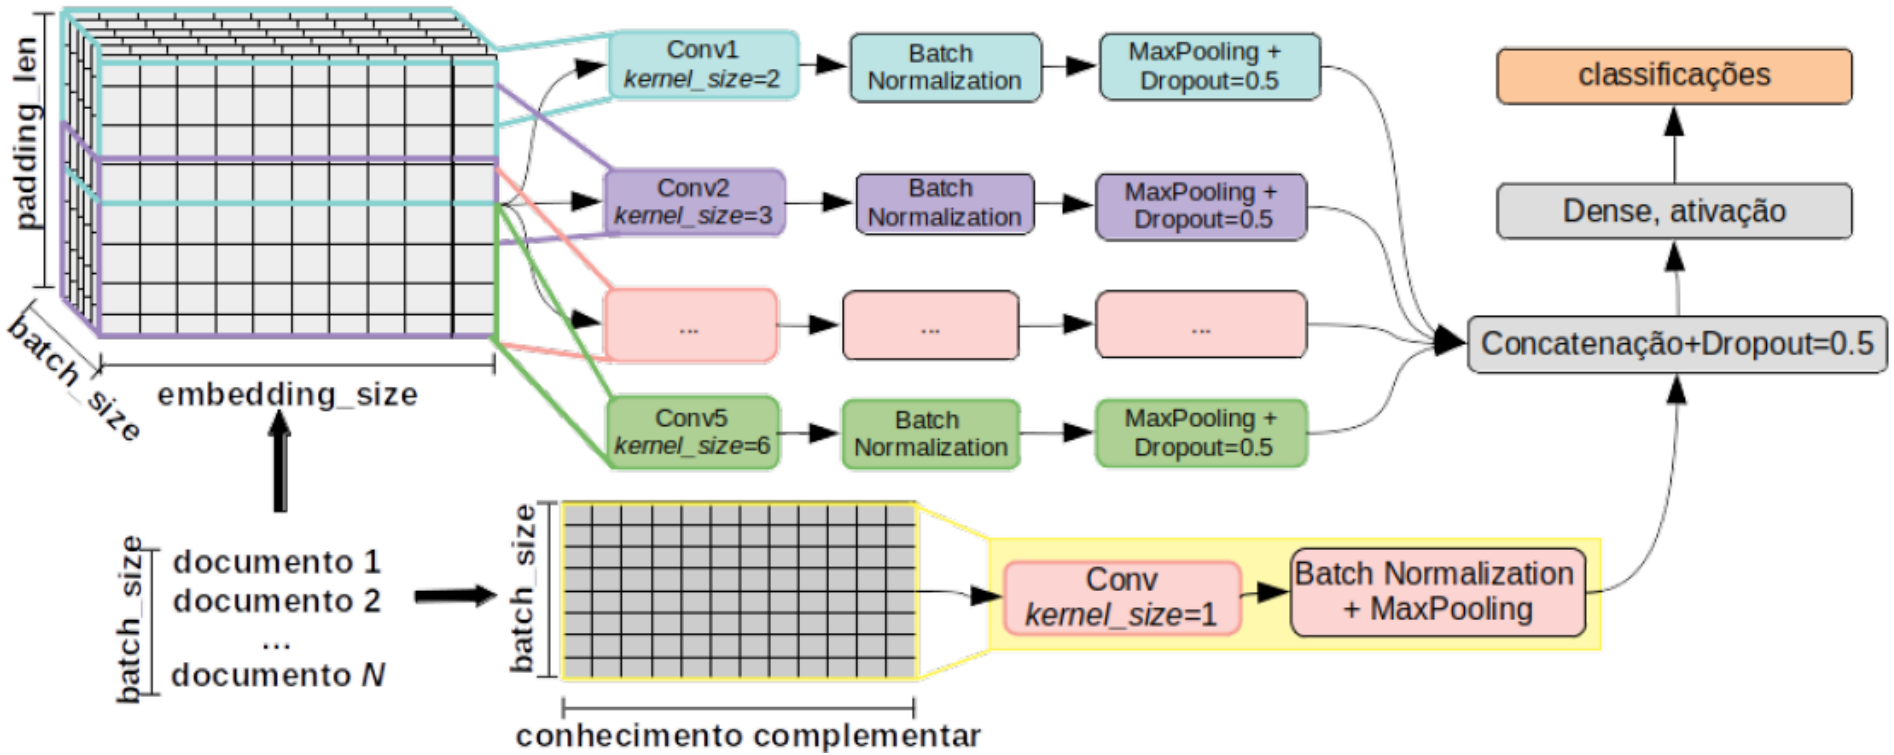
- Detecção de alinhamento ideológico: córpus GovBR de timelines de usuários hashtags favoráveis e desfavoráveis ao governo federal (e.g., #RespeitemoPresidente, #forabozo etc.)
    - Rotulação distante com base no uso de hashtags específicas
- Grupos contrário e favorável sem intersecção
- Dados foram filtrados, mantendo-se apenas tweets de conotação política utilizando-se o vocabulário da seção Política da Folha de São Paulo
- Hashtags foram removidas
- Estudo realizado com 4010 tweets selecionados aleatoriamente

Estratégias consideradas

- Mesma arquitetura CNN híbrida do experimento piloto (discurso de ódio), porém considerando (além dos embeddings e características psicolinguísticas) um terceiro modelo de bigramas sintáticos

- A arquitetura completa é comparada com todas as configurações possíveis de seus subcomponentes

Arquitetura híbrida



Trabalho realizado

- Como sistemas de baseline são usados modelos do tipo BERT e o sistema de Jiang et. al. (2019), vencedor da competição SemEval de detecção de hiperpartidarismo (baseado em um modelo ELMo com CNN).

Jiang *et al.* (2019)
baseline.bert
CNN.psico
CNN.sngram
CNN.bert
CNN.bert+psico
CNN.bert+sngram
CNN.bert+sngram+psico

- As 8 estratégias consideradas (proposta principal, seus subcomponentes e baselines) foram aplicadas às 7 tarefas de classificação (hiperpartidarismo, ideologia e alinhamento político)
    - 56 experimentos (treino + teste + avaliação)

Qual será a melhor estratégia?

Spoiler

- Configuração completa **CNN.bert+sngram+psico** de modo geral não é a melhor!

Spoiler

- Configuração completa **CNN.bert+sngram+psico** de modo geral não é a melhor!

- Resultados mais consistentes foram observados com **CNN.bert+sngram**

1/3 detecção de notícias hiperpartidárias em nível textual e autoral

Resultados 1/3: detecção de hiperpartidarismo em nível textual (notícia rotulada, à esquerda) e autoral (fonte rotulada, à direita)

Modelo	Acurácia	Grupo	
CNN.bert+sngram	**0,78***	A	
CNN.bert	0,75	A	
CNN.bert+psico	0,74	A	
Jiang *et al.* (2019)	0,72	B	
CNN.sngram	0,69	B	
baseline.bert	0,68	B	
CNN.bert+sngram+psico	0,67	B	
CNN.psico	0,47		C

Modelo	Acurácia	Grupo	
CNN.bert+psico	**0,61***	A	
CNN.bert	0,58	A	
CNN.bert+sngram	0,57	A	
CNN.sngram	0,57		B
Jiang *et al.* (2019)	0,56		B
CNN.bert+sngram+psico	0,55		B
baseline.bert	0,54		B
CNN.psico	0,53		B

2/3 detecção de ideologia em nível textual e autoral

Resultados 2/3 textual: detecção de ideologia **textual** com rótulos derivados da polaridade de opiniões

Modelo	*Esquerda* × *Direita* Acurácia	Grupo
CNN.bert+sngram	**0,78**	A
Jiang *et al.* (2019)	0,76	A
CNN.bert+psico	0,76	A
CNN.bert	0,75	A
CNN.bert+sngram+psico	0,73	B
CNN.sngram	0,70	B
CNN.psico	0,68	C
baseline.bert	0,57	D

Modelo	*Esquerda* × *Centro* × *Direita* Acurácia	Grupo
CNN.bert+sngram	**0,64**	A
Jiang *et al.* (2019)	0,62	A
CNN.bert	0,60	A
CNN.bert+psico	0,60	B
CNN.bert+sngram+psico	0,58	B
CNN.sngram	0,55	B
CNN.psico	0,52	C
baseline.bert	0,43	D

Resultados 2/3 autoral: detecção de ideologia **do indivíduo** usando rótulos autodeclarados

Modelo	*Esquerda* × *Direita* Acurácia	Grupo	
CNN.bert+sngram	**0,63**	A	
Jiang *et al.* (2019)	0,61	A	
CNN.bert+psico	0,60	A	
CNN.psico	0,59	A	
CNN.bert+sngram+psico	0,59	A	
baseline.bert	0,56	A	
CNN.sngram	0,56		B
CNN.bert	0,53		B

Modelo	*Esquerda* × *Centro* × *Direita* Acurácia	Grupo	
CNN.bert+sngram+psico	**0,42**	A	
CNN.bert+sngram	0,41	A	
CNN.bert	0,41	A	
Jiang *et al.* (2019)	0,38	A	
CNN.sngram	0,38	A	
CNN.psico	0,37		B
baseline.bert	0,37		B
CNN.bert+psico	0,36		B

3/3 detecção de alinhamento ideológico

Resultados 3/3: detecção de alinhamento ideológico com base no uso de hashtags no Twitter

Modelo	Acurácia	Grupo
CNN.bert+sngram	**0,62**	A
CNN.bert	0,61	A
CNN.bert+psico	0,60	A
CNN.bert+sngram+psico	0,59	A
Jiang *et al.* (2019)	0,58	A
baseline.bert	0,53	B
CNN.sngram	0,53	B
CNN.psico	0,52	B

Conclusões

Conclusões

- Menos é mais?

- Problema pode ter múltiplas formulações (nível textual x autoral, binário x ternário, rótulos direitos ou indiretos etc.)

- Muitas estratégias podem ter o mesmo resultado prático (em termos estatísticos)

Obrigado